

SQL puhastamine

Tiim **TOODE**

Tiimiliikmed

A	Triin Müügiandmete puhastaja
B	Jörgen Kliendiandmete puhastaja
C	Sirja Tooteandmete puhastaja
D	Tuuli Kvaliteedikontrollija



sales_test tabeli puhastamine — enne ja pärast

- Tabelis oli 5116 duplikaatset rida
- 4013 veerus duplikaadid (sale_id) → pärast 0
- 1487 puuduvat kliendiviidet (customer_id) → pärast 988 (külalisostud) → asendasin 0-ga
- Puuduva kuupäeva (NULL sale_date) ja summaga (NULL total_price) ridu pole
- Tuleviku kuupäevaga ridu 8 → pärast 0
- Sales tabelis oli enne 15 234 rida, nüüd 10 118

Järeldus: Ligi kolmandik müügitehinguid olid duplikaadid → käive ülehinnatud.
Probleem külalisostudega → kui täpselt saame kliendikäitumist analüüsida?



Kliendiandmete puhastaja

Jörgen

customers_test tabeli puhastamine

Puhastamisraport:

- 128 duplikaatset e-maili. Lisaks 380 null väärtusega emaili.
- 0 NULL eesnime, 0 NULL perenime.
- 5 erinevat nimekuju samale linnale (54 erinevat linna).
- 0 NULL telefoninumbrit, 380 NULL emaili.

Kokku 562 probleemi

Pärast puhastamist sai 54-st Eesti linnast 12 linna.

Murekoht:

Igapäevast tööd mõjutab kõige rohkem see, et puuduvad meiliaadressid, pakkumiste jms info edastamine klientidele on piiratud.



products_test tabeli puhastamine — enne ja pärast

- Products tabelis on 12 duplikaatset tootenime (sama toode kaks korda uue koodiga)
- Ei leidnud ühtegi null hinda ega puuduvat väärtust
- Puuduvad negatiivsed või äärmuslikud jaehinnad
- Ei leidnud ebajärjekindlaid kategooria nimekujusid
- Ühtlustasin kategooriate nimed

Soovitus- kontrollida duplikaatsete toodete seost teiste tabelitega ning otsustada, milline ID jääb



sales, customers ja products tabelite kvaliteedikontroll

- 1487 müüki viitab “olematule kliendile” (IS NULL)
- 0 olematu toote müüki
- 664 juhtu, kus müügihind ja tootehind ei klapi
- 592 klienti pole kunagi ostu sooritanud (2558 unikaalset klienti on ostu sooritanud)
- 12 toodet pole kunagi müüdud

Soovitus: Uurida täpsemalt nn “olematute klientide” kohta, et samad andmed oleksid kõigis süsteemides (e-pood, kassa ja Excel) ja klientide kohta, kes pole kunagi ostu sooritanud, see võib viidata, et nende klientide ostud pole registreeritud kõigis süsteemides, sama võib kehtida ka mitte müüdud toodete kohta. Oleks tarvis ühtset andmesüsteemi.

Tulemus

Mis oli meie peamine järeldus?

Andmestik vajab tõsist puhastust, eriti suur duplikaatide arv oli sales tabelis (5116): kolme tabeli peale kokku leiti ja parandati üle 6000 andmekvaliteedi probleemi.

Soovitus Toomasele

Andmesisestuse loogika tuleks üle vaadata, et tulevikus selliseid vigu vältida – duplikaadid ja puuduvad andmed ei teki iseenesest.

Mis meid üllatas?

Müügitabeli suur duplikaatide arv, linnade nimekujude lai variatsioon, samas positiivne üllatus, et mõnedes veergudes ei leitud üldse vigu (eriti products tabelis).

MEESKOND: TOODE | NÄDAL: 2 | TEGELANE: Toomas Kask |

ANDMEKVALITEEDI KOONDRAPORT

PEAMISED LEIUD:

1. Triin, müügiandmete puhastaja: leitud 5508 probleemi – korduvad sale_id väärtused (4018), NULL customer_id (1487), tulevikukuuäpäevad (8) eemaldatud. Alles jäi 988 NULL sales_id ehk külalisostu.
2. Jörgen, kliendiandmete puhastaja: leitud 562 probleemi – [128 duplikaatset emaili, 380 NULL väärtusega emaili. Erineva formaadiga linnade arv oli 54, update käsklusega uuendades jäi alles 12 erinevat linna.
3. Sirja, tooteandmete puhastaja: leitud 12 probleemi – duplikaatsed tootenimed.
4. Tuuli, kvaliteedikontrollija: leitud 2655 probleemi – 1487 müüki viitab "olematule kliendile" (IS NULL), 664 juhtu, kus müügihind ja tootehind ei klapi, 592 klienti pole kunagi ostu sooritanud, 12 toodet pole kunagi müüdud.

SUURIM ÜLLATUS:

Müügitabeli suur duplikaatide arv, linnade nimekujude lai variatsioon, samas positiivne üllatus, et mõnedes veergudes ei leitud üldse vigu (eriti products tabelis).

SOOVITUS TOOMASELE:

Vaadata üle andmesisestuse loogikad, et tulevikus duplikaate ja vigaseid andmeid vältida. Oleks tarvis ühtset andmesüsteemi.

PUUDUVAD ANDMED:

Miinusega summad - kas need on tagastused, sisestusvead, tühistatud ost vms. Tuleks uurida, millega tegemist. Need vajavad eraldi ärireeglite kontrolli. Kas NULL väärtusega kliendiviited ikkagi on kõik külalisostud?